

AkıllıSınıf AI: Yapay Zekâ ve Otomasyon Destekli Bütünleşik Sınıf Yönetimi ve Erken Uyarı Sistemi — Tasarım ve Ön Değerlendirme

Rodina Amr Mukhtar

Bilgisayar Mühendisliği Bölümü, Kastamonu Üniversitesi

Kastamonu, Türkiye

ID 0009-0002-0696-0929

Özet—Eğitim kurumlarındaki dijitalleşme dönüşümü, öğretmenlerin idari yükünü artırırken bireysel öğrenci takibini güçleştirmektedir. Bu çalışma, Tasarım Bilimi Araştırması (Design Science Research – DSR) yöntemi çerçevesinde geliştirilen "AkıllıSınıf AI" sisteminin mimari tasarımını ve ön fizibilite değerlendirmesini sunmaktadır. Platform; sınıf yönetimi, ödev-yoklama-not takibi, gerçek zamanlı mesajlaşma, çok etkenli risk puanlaması, büyük dil modeli (BDM) destekli müdahale planı üretimi, bağlam-zenginleştirilmiş öğrenci asistanı ve 13 bağımsız n8n otomasyon akışından oluşan yedi modül içermektedir. İki öğretmen ve 15 öğrenciden oluşan sekiz haftalık pilot çalışmada sistem, risk sınıflandırmasında Cohen $\kappa = 0.79$ gözlemciler arası uyum katsayısı ve müdahale planı değerlendirmesinde 4.2/5.0 Likert skoru elde etmiştir. Bu bulgular operasyonel uygulanabilirliğe ilişkin ön fizibilite kanıtları sunmakta olup nedensellik veya genellenebilirlik iddiasında bulunmamakta; daha geniş örneklem ve kontrol gruplu çalışmalarla doğrulanmayı gerektirmektedir.

Anahtar Sözcükler—eğitim teknolojisi; erken uyarı sistemi; büyük dil modeli; iş akışı otomasyonu; sınıf yönetimi; Tasarım Bilimi Araştırması; öğrenci risk puanlaması.

I. GİRİŞ

Eğitimde yapay zekâ uygulamaları son on yılda ivme kazanmış; makine öğrenimi, doğal dil işleme ve büyük veri analitiği teknolojileri, geleneksel öğrenme yönetim sistemlerinin (LMS) yetersiz kaldığı alanlarda devreye girmiştir. [1] [2] Kaynak kısıtlı ortamlarda ticari platformlara olan bağımlılık ise dijital dönüşümün önündeki yapısal engellerden biri olmayı sürdürmektedir. [3]

Öğrenci başarısının öngörülmesi ve risk altındaki öğrencilerin erken tespiti, eğitim analitiği alanının temel araştırma gündemini oluşturmaktadır. Romero ve Ventura [4] eğitimsel veri madenciliğinin (EDM) bağımsız bir disiplin hâline gelme sürecini belgelemiştir. Baker [5] LMS günlük verilerine uygulanan EDM yöntemlerinin öğrenci başarısızlık tahminine katkısını ortaya koymuştur.

Yapay zekâ destekli erken uyarı sistemleri (EWS), devamsızlık, geç teslim ve not düşüşü gibi sinyalleri izleyerek proaktif müdahale fırsatı sunmaktadır. [6] [7] Arnold ve Pistilli [8] Course Signals ile bu alandaki öncü ampirik kanıtı üretmiş; ancak söz konusu sistem ve benzerleri risk görselleştirmesi sunmakta olup otomatik müdahale planı üretimi içermemektedir. Bu eksiklik, AkıllıSınıf AI'nın temel farklılaşma noktasını oluşturmaktadır. BDM'lerin eğitim sistemlerine entegrasyonu son iki yılda hızla genişlemiştir. [9] [10] İş akışı otomasyon platformları ise idari süreçleri standartlaştırma konusunda belgelenmiş etkinliğe sahiptir. [11]

Özgün katkılar:

(C1) Sınıf yönetimi, erken uyarı, BDM asistanı ve otomasyon katmanlarını açık kaynaklı bileşenlerle

desteklenen düşük lisans maliyetli tek platformda birleştiren DSR tabanlı mimari tasarım;

(C2) İç tutarlılığı sağlanmış ağırlıklı toplam risk puanlama algoritması ve otomatik müdahale planı üretim mekanizması;

(C3) Anlık Airtable verisiyle bağlam-zenginleştirilmiş istem (context-enriched prompting) tabanlı pedagojik kısıtlanmalı BDM asistanı;

(C4) 13 n8n otomasyon akışından oluşan sıfır-dokunuş operasyonel katmanın tasarımı ve ön fizibilite değerlendirmesi.

II. İLGİLİ ÇALIŞMALAR

A. Eğitim Analitiği ve EDM

Siemens ve Long [12] öğrenci davranış verilerinin sistematik analizi yoluyla pedagojik kararların iyileştirilebileceğini göstermiştir. Campbell, DeBlois ve Oblinger [13] akademik analitiğin kurumsal yönetime entegrasyonunu incelemiş; Papamitsiou ve Economides [6] ampirik EDM kanıtlarını sistematik biçimde sentezlemiştir.

Credé, Roch ve Kieszczyńska [14] meta-analiz yöntemiyle devam davranışının not ortalamasıyla korelasyonunu $r = 0.41$ olarak hesaplamış; bu bulgu devamsızlığı risk modellerinde birincil değişken olarak konumlandırmayı meşrulaştırmaktadır. Romer [15] ödev teslim davranışı ile akademik başarı arasındaki ilişkiyi belgelemiştir.

B. Erken Uyarı Sistemleri

EWS literatüründe lojistik regresyon ve karar ağacı gibi klasik yöntemler öne çıkmıştır. [8] [16] Daha güncel araştırmalar LSTM ve Transformer mimarilerini eğitim

ortamlarına uyarlamış; büyük ve dengeli veri kümeleriyle %90'ın üzerinde F1 skorları bildirilmiştir. [17] [18] Bununla birlikte yüksek doğruluk oranları genellikle büyük veri kümeleri gerektirmekte; bu durum sınırlı veri koşullarında çalışan kurumlar için ayrı bir zorluk oluşturmaktadır. [19]

Essa ve Ayad [20] ensemble yaklaşımın tek modele kıyasla daha güvenilir risk skorları ürettiğini göstermiştir. Mevcut EWS çözümlerinin ortak eksikliği, risk sinyali tespit etmekle yetinip otomatik pedagojik müdahale adımı üretememesidir; bu boşluğun doldurulması bu çalışmanın temel motivasyonunu oluşturmaktadır.

C. BDM ve Bağlam-Zenginleştirilmiş İstem

BDM'lerin eğitim bağlamlarında en önemli sorunu gerçeğe aykırı (hallucination) içerik üretme riskidir. [9] Bu riski azaltmak için bağlam-zenginleştirilmiş istem teknikleri, modele alan özgü veri ve kısıtlamalar sağlamaktadır. [21] Lewis ve diğerleri [22] harici belge depolarından yararlanan nesil mimarileri önermiş; Gao ve diğerleri [23] bu tür yaklaşımların bilgi-yoğun alanlardaki geniş uygulama yelpazesini haritalamıştır. AkıllıSınıf AI'da anlık Airtable verisi istem bağlamına enjekte edilmekte; ancak vektör indeksleme veya semantik arama içerilmemektedir.

D. Düşük Kod Otomasyon Platformları

n8n, Zapier ve Make gibi görsel otomasyon araçları idari iş yükünü azaltma konusunda belgelenmiş etkinliğe sahiptir. Richardson [11] rutin bildirim ve raporlama görevlerinde bu araçların ciddi zaman tasarrufu sağladığını raporlamıştır. Trueman ve Hartley [24] zaman yönetimi ile akademik performans arasındaki ilişkiye dikkat çekmiştir.

III. ARAŞTIRMA YÖNTEMİ

Bu çalışma, Hevner ve diğerleri [25] tarafından tanımlanan Tasarım Bilimi Araştırması (DSR) yöntemi çerçevesinde yürütülmüştür. DSR; insan ve örgütsel sorunlara çözüm üretmek amacıyla yapay artefaktlar tasarlayan ve bunları titizlikle değerlendiren bir araştırma paradigmasıdır. Çalışma DSR'nin üç temel çıktısını kapsamaktadır: (i) problem tanımlama ve motivasyon, (ii) tasarım ve geliştirme, (iii) prototip ön değerlendirme.

A. Çalışma Türü ve Kapsamı

Bu çalışma bir Sistem Tasarımı ve Ön Fizibilite Değerlendirmesi çalışmasıdır. Kontrollü bir deneysel çalışma değildir; bulgular sistemin operasyonel uygulanabilirliğine ilişkin ön kanıtlar sunmakta olup nedensellik iddiasında bulunmamaktadır. Öğrenci akademik başarısı üzerindeki uzun vadeli etki, kontrol gruplu ve geniş örneklemli gelecek çalışmaların konusunu oluşturmaktadır.

B. Katılımcılar

Ön değerlendirme, 2025–2026 güz dönemi boyunca gönüllülük esasıyla katılan iki öğretmen ve 15 lisans

öğrencisiyle gerçekleştirilmiştir. Tüm katılımcılardan bilgilendirilmiş onam alınmış, veriler anonimleştirilmiş ve yalnızca sistem değerlendirme amacıyla kullanılmıştır. BDM'ye iletilen bağlam verisi, doğrudan tanımlayıcı bilgi içermeyecek şekilde yapılandırılmıştır.


C. Veri Toplama

Sekiz haftalık değerlendirmede kullanılan araçlar: (i) sistem günlükleri: 120 yoklama, 45 ödev teslimi, 210 not girişi, 38 mesajlaşma oturumu; (ii) risk sınıflandırma karşılaştırması: sistem ile iki bağımsız öğretmen değerlendirmesi; (iii) müdahale planı değerlendirme formu: pedagojik uygunluk, uygulanabilirlik ve tarafsız dil kriterlerine göre 5 puanlı Likert ölçeği (14 form); (iv) teknik performans günlüğü: webhook yanıt süreleri ve otomasyon yürütme kayıtları.

IV. SİSTEM MİMARİSİ

AkıllıSınıf AI, endişelerin ayrılması (Separation of Concerns) ilkesi temelinde yapılandırılmış beş katmanlı bir bulut yerel mimariye sahiptir. [26] Her katman bağımsız olarak ölçeklenebilir ve değiştirilebilir biçimde tasarlanmıştır.

Şekil 1. AkıllıSınıf AI — Katmanlı Sistem Mimarisi



Tablo 1. Sistem Katmanları, Teknolojiler ve Sorumluluklar

Katman	Teknoloji	Sorumluluk
Sunum	Next.js 14 + Vercel	SSR, routing, UI/UX
Auth	Supabase Auth (JWT)	Kimlik doğ., RLS, roller

Katman	Teknoloji	Sorumluluk
Gerçek Zamanlı	Supabase Realtime	Chat ve bildirim WS
Veri	Airtable REST API	İlişkisel veri modeli
BDM	OpenRouter API	Analiz, asistan, plan
Otomasyon	n8n (13 akış)	Tetikleyici + eylem

A. Kimlik Doğrulama ve Veri Katmanı

Supabase Auth, JWT tabanlı oturum ve Satır Düzeyi Güvenlik (RLS) politikaları sağlamaktadır. Temel Airtable tabloları: Kullanıcılar, Sınıflar, Sınıf_Uyelikleri, Ödevler, Ödev_Teslimleri, Yoklamalar, Notlar, Risk_Ozetleri, AI_Tahminleri, Risk_Sinyalleri, Mudahale_Planları, Bildirimler ve Haftalık_Raporlar. Akış 09, veri kalite denetimini haftalık periyotlarda otomatik gerçekleştirmektedir. [27]

B. BDM Entegrasyonu

Her BDM çağrısı öncesinde Airtable'dan anlık çekilen öğrenci, sınıf ve risk verileri istem bağlamına enjekte edilmektedir. Bu bağlam-zenginleştirilmiş istem yaklaşımı; vektör indeksleme, embedding veya semantik arama içermemektedir. Pedagojik kısıtlama politikası gereği model; sınav cevabı, tanımlayıcı kişisel veri ve sistem gizli bilgisi üretimini önleyen açık sistem yönergeleriyle çalışmaktadır.

V. FONKSİYONEL MODÜLLER

A. Sınıf ve Yoklama Yönetimi

Öğretmen benzersiz katılım kodu üretilen bir sınıf oluşturur; öğrenci bu kodu kullanarak katılım isteği gönderir. Akış 04 isteği anlık olarak öğretmene bildirir; onay sonrası öğrenci tüm sınıf içeriklerine erişim kazanır. Yoklama kayıtları seans bazlı (Var/Yok/Geç) tutulmakta, Akış 03 devamsızlık eşiğini aşan öğrencilere ve öğretmene otomatik uyarı göndermektedir. [28]

B. Ödev, Not ve Bildirim Modülü

Ödevler Kolay/Orta/Zor zorluk seviyesiyle tanımlanmakta; Akış 02 son teslim tarihine yaklaşıldığında otomatik hatırlatma göndermektedir. Notlar kümülatif olarak kaydedilmekte, Akış 05 yeni not ilanlarında öğrencilere otomatik bildirim göndermektedir. Supabase Realtime WebSocket altyapısı; sınıf grup sohbeti ve öğretmen-öğrenci özel görüşmesini desteklemekte, Akış 13 ödev dosyalarını Google Drive'a otomatik arşivlemektedir. [29]

C. Erken Uyarı ve Risk Algoritması

Erken uyarı motoru her öğrenci için aşağıdaki ağırlıklı toplam formülüyle 0–100 ölçeğinde bir risk puanı (RP) hesaplamaktadır:

$$RP = 100 \times [0.35 \times D + 0.30 \times (1 - T) + 0.35 \times (1 - N')]$$

Değişken tanımları: D, T ve N' tümü [0,1] aralığında normalize edilmiş değişkenlerdir. D = devamsızlık oranı (devamsız seans / toplam seans); T = ödev teslim oranı (teslim edilen / toplam ödev sayısı); N' = bileşik not skoru, aşağıdaki formülle hesaplanmaktadır:

$$N' = 0.70 \times N_{avg} + 0.30 \times Trend_{norm}$$

burada N_avg = normalize edilmiş genel not ortalaması; Trend_norm = son üç nota uygulanan en küçük kareler doğrusal regresyonundan elde edilen eğim katsayısı (beta), aşağıdaki min-max dönüşümüyle [0,1] aralığına sıkıştırılmaktadır:

$$Trend_{norm} = clip((beta - beta_{min}) / (beta_{max} - beta_{min}), 0, 1)$$

burada beta_min = -10 ve beta_max = +10 puan/seans olarak sabitlenmiştir; bu aralığın dışındaki değerler 0 veya 1'e sıkıştırılmaktadır (clipping). Pozitif eğim (not artışı) → Trend_norm → 1; negatif eğim (not düşüşü) → Trend_norm → 0.

Ağırlık değerleri, Credé ve diğerlerinin [14] devamsızlık–GPA meta-analizinden (r = 0.41) ve Romer'in [15] ödev teslimi ile performans bulgularından hareketle heuristik olarak belirlenmiştir. Bu ağırlıkların ampirik optimizasyonu gelecek veri toplama sürecine bırakılmıştır.

Risk kategorileri: Düşük (RP ≤ 40), Orta (41–60), Yüksek (61–84), Kritik (RP ≥ 85). Bu eşikler öğretmenlerle yürütülen tasarım oturumlarında belirlenmiş operasyonel tercihler olup istatistiksel doğrulama gerektirmektedir. Yüksek/Kritik kategorisindeki öğrenciler için Akış 07 otomatik müdahale planı üretmekte, Akış 10 öğretmene risk sinyali e-postası göndermektedir.

Şekil 2. Örnek BDM Müdahale Planı Çıktısı (Akış 07 — Anonimleştirilmiş)

[RISK SİNYALİ RAPORU — YÜKSEK KATEGORİ]
Öğrenci ID: O-007 | Sınıf: BIL-301 | RP = 78 | Kategori: Yüksek

Tetikleyen Risk Faktörleri:

Devamsızlık oranı: %42 (esik: %30)
Gec teslim sayısı: 3 / 5 ödev
Not trendi (Trend_norm): 0.18 — kuvvetli dusus sinyali

Onerilen Mudahale Adimlari:

1. Bu hafta icerisinde bireysel gorusme planlayiniz.
2. Eksik odevler icin ek sure ve destek sunulacaktır.
3. Onumuzdeki 2 hafta yogun yoklama takibi uygulayiniz.
4. Gerekirse akademik danismanlikla koordinasyon.

Tahmini sure: 14 gun | Uretim: n8n Akis 07 + OpenRouter BDM

D. BDM Asistanı ve Otomasyon Akışları

BDM entegrasyonu iki bağlamda çalışmaktadır: (i) Öğrenci asistanı: ders çalışma ve sistem kullanımı desteği; (ii) Öğretmen asistanı: sınıf özeti, risk yorumu, haftalık ders önerileri (Akış 12). Akış 11, dış sistemlerden gelen

webhook isteklerine gerçek zamanlı BDM yanıtı döndürmektedir. [9] [30]

Tablo II. n8n Otomasyon Akışları — Tetikleyici ve İşlev

No	Tetikleyici	İşlev
01	Haftalık Schedule (Pzt 09:00)	Sınıf bazlı risk raporu üretimi ve kaydı
02	Günlük Schedule	Ödev teslim tarihi hatırlatma e-postası
03	Günlük Schedule	Devamsızlık eşiği aşıldığında uyarı e-postası
04	Airtable Trigger	Katılım isteğinde öğretmen bildirimi
05	Airtable Trigger	Not ilanında öğrenci e-posta bildirimi
06	Haftalık Schedule	Bireysel BDM performans tahmini üretimi
07	Airtable Trigger	Yüksek/Kritik risk — müdahale planı üretimi
08	Haftalık Schedule	Öğrenciye haftalık gelişim özeti e-postası
09	Haftalık Schedule	Veri kalite denetimi ve denetim kaydı
10	Haftalık Schedule	Risk sinyali tespiti ve öğretmen uyarısı
11	Webhook (HTTP POST)	Gerçek zamanlı BDM asistan yanıtı (API)
12	Haftalık Schedule	BDM destekli haftalık ders ve sınıf önerisi
13	Airtable Trigger	Ödev dosyalarını Google Drive'a arşivleme

VI. ÖN DEĞERLENDİRME

A. Değerlendirme Düzenliği ve Sınırlılıklar

Bu bölüm DSR çerçevesi kapsamında yürütülen kontrollü pilot çalışmanın bulgularını sunmaktadır. Çalışmada bağımsız bir eğitim çıktısı ölçülmemiştir; değerlendirme operasyonel tutarlılık, risk sınıflandırma güvenilirliği ve müdahale planı algılanan kalitesine odaklanmıştır. Kontrol grubu bulunmamakta, baseline karşılaştırması yapılmamakta; bu durum çalışmayı ön fizibilite kanıtı düzeyinde konumlandırmaktadır.

B. Bulgular

Risk sınıflandırma güvenilirliği, sistem çıktısı ile iki bağımsız öğretmenin değerlendirmeleri arasında Cohen $\kappa = 0.79$ olarak hesaplanmıştır. [31] Landis ve Koch [31] ölçeğine göre bu değer 'güçlü uyum' kategorisine karşılık gelmektedir. Bu ölçüm, sistem ile öğretmen değerlendirmesinin tutarlılığını ölçmekte; bağımsız bir Ground Truth karşısında tahmin doğruluğunu değerlendirmemektedir.

BDM tarafından üretilen 14 müdahale planı ortalama 4.2 ± 0.6 Likert puan almıştır. Değerlendirme boyutları: pedagojik uygunluk, uygulanabilirlik ve öğrenciyi suçlayıcı dil içermeme. Otomasyon akışları sekiz hafta boyunca 91 planlı yürütmeden 88'ini tamamlamış, %96.7 işletim tutarlılığı elde edilmiştir.

Tablo III. Ön Değerlendirme Bulguları Özeti

Ölçüm	Sonuç
Risk sınıfı. gözl. arası uyumu (κ)	0.79 (Güçlü)
Müdahale planı Likert skoru	$4.2 \pm 0.6 / 5.0$
Otomasyon işletim tutarlılığı	88/91 = %96.7
Webhook ortalama yanıt süresi	1.4 saniye
Tespit edilen risk sinyali	7 (8 haftalık dönem)
Bağımsız eğitim çıktısı	— (gelecek çalışma)
Baseline karşılaştırması	— (gelecek çalışma)

VII. TARTIŞMA

Ön bulgular, AkıllıSınıf AI'nın risk sınıflandırma ve pedagojik müdahale planı üretimi konularında operasyonel uygulanabilirliğine ilişkin erken kanıtlar sunmaktadır. Course Signals [8] ve benzeri EWS çözümleriyle karşılaştırıldığında sistemin temel farkı, risk görselleştirmesinin ötesinde otomatik ve yapılandırılmış müdahale adımları önermesidir. Ancak bu farkın uzun vadeli pedagojik etkisi, kontrol gruplu ve geniş örneklemli bir çalışmayla doğrulanmadan kesinleştirilemez.

Mevcut tasarım; açık kaynaklı bileşenler ve düşük lisans maliyeti sayesinde, kaynak kısıtlı eğitim ortamlarında benzer platformlara kıyasla daha erişilebilir bir yapı sunabilme potansiyeli taşımaktadır. Bununla birlikte bu iddia, sistematik maliyet karşılaştırması ve ölçeklenme deneyleri olmaksızın kesin bir sonuç olarak ileri sürülemez.

Pilot çalışmanın temel sınırlılıkları: (i) iki öğretmen ve 15 öğrenci genellenebilirlik için yetersizdir; (ii) kontrol grubu yoktur; (iii) risk ağırlıkları istatistiksel olarak optimize edilmemiştir; (iv) müdahale planı memnuniyeti bağımsız pedagojik değerlendirme değildir. Airtable REST API oran sınırları (ücretsiz katmanda 5 istek/saniye) geniş kurumsal dağıtımlarda darboğaz oluşturabilmekte; bu durumda PostgreSQL tabanlı bir altyapıyla değiştirilmesi önerilmektedir. [19] [32]

VIII. ARAŞTIRMA ÖNERİLERİ

Ön fizibilite bulguları ve tanımlanan sınırlılıklar ışığında dört öncelikli araştırma yönü önerilmektedir:

A. Büyük Örneklem, Kontrol Grubu ve Eğitim Çıktısı

Sistemin gerçek pedagojik etkisini ölçmek için deney-kontrol gruplu, en az 200 öğrencili ve tam akademik dönem süren bir çalışma tasarlanmalıdır. Bağımsız çıktı değişkenleri (not artışı, bırakma oranı, ödev teslim

oranındaki değişim) ölçülmeli; yalnızca manuel değerlendirme kullanan bir baseline koşulu dahil edilmelidir. [6] [19]

B. Risk Ağırlığı ve Eşik Optimizasyonu

Mevcut heuristik ağırlıkların gerçek başarı ve bırakma verileriyle lojistik regresyon veya k-katlı çapraz doğrulama yoluyla ampirik olarak optimize edilmesi gerekmektedir. beta sınır değerlerinin (beta_min, beta_max) bağlam bağımlılığı da ayrıca incelenmelidir. [17] [18]

C. BDM Çıktı Kalitesi ve Önyargı Denetimi

BDM tarafından üretilen müdahale planlarının pedagojik doğruluk, önyargı ve güvenlik boyutlarında bağımsız uzman değerlendirmesiyle sistematik olarak incelenmesi kritik öneme sahiptir. [9] [10]

D. Yasal Uyumluluk ve Gizlilik Mimarisi

Veri minimizasyonu, anonimleştirme, rıza yönetimi ve denetim izi bileşenlerinden oluşan KVKK/GDPR uyumluluk mimarisinin sisteme entegrasyonu öncelikli araştırma gündemini oluşturmaktadır. [33]

IX. SONUÇ

Bu çalışma, DSR yöntemi çerçevesinde geliştirilen AkıllıSınıf AI platformunun mimari tasarımını, fonksiyonel modüllerini ve sekiz haftalık ön fizibilite değerlendirmesinin bulgularını sunmuştur. İç tutarlılığı sağlanmış risk puanlama formülü ($RP = 100 \times [\dots]$), min-max normalleştirmeli Trend_norm hesaplaması, bağlam-zenginleştirilmiş BDM entegrasyonu ve 13 otomasyon akışından oluşan operasyonel katman, sistemin bütünleşik bir eğitim teknolojisi çözümü olarak ilk fizibilite adımı tamamladığını göstermektedir.

Cohen $\kappa = 0.79$ gözlemciler arası uyumu ve 4.2/5.0 müdahale planı memnuniyeti erken göstergeler olarak yorumlanmaktadır. Bu bulgular, sistemin bağımsız eğitim çıktıları ve karşılaştırmalı baseline üzerinden değerlendirildiği geniş örneklemli çalışmalarla doğrulanmayı gerektirmektedir. Bu çalışma, söz konusu araştırma sürecinin başlangıç noktası ve prototip referansı olarak konumlandırılmaktadır.

TEŞEKKÜR

Yazar, ön değerlendirme sürecine gönüllü olarak katılan öğretmen ve öğrencilere teşekkür eder.

KAYNAKLAR

[1] C. Romero ve S. Ventura, "Educational data mining: A survey from 1995 to 2005," *Expert Systems with Applications*, cilt 33, sayı 1, ss. 135–146, 2007.
[2] G. Siemens, "Learning analytics: Envisioning a research discipline," *Proc. LAK '12*, New York: ACM, 2012, ss. 4–8.
[3] T. Anderson, Ed., *The Theory and Practice of Online Learning*, 2. baskı. Edmonton: AU Press, 2008.
[4] C. Romero ve S. Ventura, "Educational data mining and learning analytics: An updated survey," *WIREs Data Mining and Knowledge Discovery*, cilt 10, sayı 3, e1355, 2020.

[5] R. S. J. Baker, "Data mining for education," in *International Encyclopedia of Education*, cilt 7. Oxford: Elsevier, 2010.
[6] Z. Papamitsiou ve A. A. Economides, "Learning analytics and educational data mining in practice," *Educational Technology & Society*, cilt 17, sayı 4, ss. 49–64, 2014.
[7] D. Ifenthaler ve C. Schumacher, "Student perceptions of privacy principles for learning analytics," *Educational Technology Research and Development*, cilt 64, sayı 5, ss. 923–938, 2016.
[8] E. Arnold ve M. D. Pistilli, "Course signals at Purdue: Using learning analytics to increase student success," *Proc. LAK '12*, New York: ACM, 2012, ss. 267–270.
[9] E. Kasneci ve diğerleri, "ChatGPT for good? On opportunities and challenges of large language models for education," *Learning and Individual Differences*, cilt 103, 102274, 2023.
[10] D. Baidoo-Anu ve L. O. Ansah, "Education in the era of generative AI," *Journal of AI*, cilt 7, sayı 1, ss. 52–62, 2023.
[11] B. Richardson, "Automating administrative workflows in higher education," *Journal of Educational Technology Systems*, cilt 51, sayı 2, ss. 198–217, 2022.
[12] G. Siemens ve P. Long, "Penetrating the fog: Analytics in learning and education," *EDUCAUSE Review*, cilt 46, sayı 5, ss. 30–40, 2011.
[13] J. P. Campbell, P. B. DeBlois ve D. G. Oblinger, "Academic analytics: A new tool for a new era," *EDUCAUSE Review*, cilt 42, sayı 4, ss. 40–57, 2007.
[14] M. Credé, S. G. Roch ve U. M. Kieszczynka, "Class attendance in college: A meta-analytic review," *Review of Educational Research*, cilt 80, sayı 2, ss. 272–295, 2010.
[15] D. Romer, "Do students go to class? Should they?" *Journal of Economic Perspectives*, cilt 7, sayı 3, ss. 167–174, 1993.
[16] A. Essa ve H. Ayad, "Student success system: Risk analytics using ensembles of predictive models," *Proc. LAK '12*, New York: ACM, 2012, ss. 158–161.
[17] C. Romero ve S. Ventura, "Data mining in education," *WIREs Data Mining and Knowledge Discovery*, cilt 3, sayı 1, ss. 12–27, 2013.
[18] J. Xu ve diğerleri, "Predicting student performance using machine learning: A systematic review," *IEEE Access*, cilt 9, ss. 60567–60586, 2021.
[19] T. Barnes ve J. Stamper, "Toward automatic hint generation for logic proof tutoring," *Proc. ITS '08*, Berlin: Springer, 2008.
[20] A. Essa ve H. Ayad, "Improving student success using predictive models," *Research in Learning Technology*, cilt 20, 2012.
[21] X. Zhai ve diğerleri, "A review of AI in education from 2010 to 2020," *Complexity*, cilt 2021, 8812542, 2021.
[22] P. Lewis ve diğerleri, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *NeurIPS 2020*, cilt 33, ss. 9459–9474.
[23] Y. Gao ve diğerleri, "Retrieval-augmented generation for LLMs: A survey," *arXiv:2312.10997*, 2023.
[24] M. Trueman ve J. Hartley, "Time-management skills and academic performance," *Higher Education*, cilt 32, sayı 2, ss. 199–215, 1996.
[25] A. R. Hevner ve diğerleri, "Design science in information systems research," *MIS Quarterly*, cilt 28, sayı 1, ss. 75–105, 2004.
[26] M. Fowler, *Patterns of Enterprise Application Architecture*. Boston: Addison-Wesley, 2002.
[27] Supabase, "Row Level Security," *Supabase Docs*, 2024.

- [28] L. Johnson, S. Adams Becker ve V. Estrada, NMC Horizon Report: 2019 Higher Education Edition. Louisville, CO: EDUCAUSE, 2019.
- [29] P. Dillenbourg, "What do you mean by collaborative learning?" in Collaborative-Learning. Oxford: Elsevier, 1999.
- [30] D. Ifenthaler, "Are higher education institutions prepared for learning analytics?" TechTrends, cilt 59, sayı 3, ss. 21–27, 2015.
- [31] J. R. Landis ve G. G. Koch, "The measurement of observer agreement for categorical data," Biometrics, cilt 33, sayı 1, ss. 159–174, 1977.
- [32] V. Tinto, Leaving College: Rethinking the Causes and Cures of Student Attrition, 2. baskı. Chicago: Univ. of Chicago Press, 1993.
- [33] European Parliament ve Council of the EU, "Regulation 2016/679 — GDPR," Official Journal of the European Union, 2016.
- [34] J. Cohen, "A coefficient of agreement for nominal scales," Educational and Psychological Measurement, cilt 20, sayı 1, ss. 37–46, 1960.
- [35] J. Hattie, Visible Learning: A Synthesis of Over 800 Meta-Analyses. London: Routledge, 2009.
- [36] B. S. Bloom, Taxonomy of Educational Objectives. New York: David McKay, 1956.